Universidad Autónoma del Estado de México

FACULTAD DE INGENIERÍA

PLAN DE ESTUDIOS:
Licenciatura de Ingeniería en Computación

UNIDAD DE APRENDIZAJE:
Administración de Proyectos Informáticos

Documento de Transferencia y Diseño: Nexus FI

Integrantes del Equipo 404:

- Fernando Azuara Ibarra
- Santiago Cuevas Sánchez
- Aarón Nevid Domínguez Fuentes
- Joaquín Ulises García Álvarez
- Daniel Aguilar Sánchez
- Azuleica Betsabel de la Cruz González
- Ángel Israel de la Cruz Martínez
- Joan Alexis Ocaña Martínez

GRUPO: O2

DOCENTE:
I. EN C. CÍNTIA GONZÁLEZ MIRELES

Toluca, Estado de México, 11 de noviembre de 2026

ÍNDICE GENERAL

CONTROL DE VERSIONES DEL DOCUMENTO 7
CAPÍTULO 1. INTRODUCCIÓN Y CÓMO USAR ESTE DOCUMENTO 8
1.1 Propósito 8
1.2 Qué es Nexus FI 8
1.3 Estado del proyecto al 11 de noviembre de 2026 8
1.4 Ruta de lectura según tu perfil 9
1.5 Documentos relacionados 9
1.6 Convenciones 10
CAPÍTULO 2. ESPECIFICACIÓN DE REQUISITOS (SRS CONDENSADO) 11
2.1 Descripción general 11
2.2 Usuarios y roles 11
2.3 Alcance de la prueba piloto 11
2.4 Requisitos funcionales 12
2.5 Requisitos no funcionales 12
2.6 Reglas de negocio y parámetros vigentes 13
2.7 Casos de uso principales 13
2.8 Supuestos, restricciones y dependencias 14
CAPÍTULO 3. DISEÑO DEL SOFTWARE (SDD CONDENSADO) 15
3.1 Vista general de la arquitectura 15
3.2 Estructura del repositorio 15
3.3 Componentes 16
3.4 Flujo de una consulta 17
3.5 Acervo, ingesta y base vectorial 18
3.6 Modelo de datos 19
3.7 Interfaz de programación (API) 20
3.8 Modelos y cuotas 21
3.9 Seguridad 21
3.10 Frontend 22
3.11 Infraestructura y apagado automático 22
3.12 Decisiones de diseño clave 23

CAPÍTULO 4. PUESTA EN MARCHA EN TU EQUIPO 24
4.1 Obtener el código e instalar 24
4.2 Configurar el archivo .env 24
4.3 Base vectorial y documentos originales 24
4.4 Crear cuentas de prueba y arrancar 25
4.5 Comprobar que todo funciona 25
CAPÍTULO 5. OPERACIÓN Y MANTENIMIENTO 26
5.1 Tareas recurrentes 26
5.2 Despliegue en la instancia EC2 26
5.3 Agregar o actualizar documentos del acervo 27
5.4 Cambiar modelos o cuotas 27
5.5 Habilitar otra carrera 27
5.6 Gestión de cuentas 28
5.7 Monitoreo y costos 28
5.8 Respaldo y recuperación 28
5.9 Solución de problemas 29
CAPÍTULO 6. CALIDAD Y PRUEBAS 30
6.1 Pruebas automáticas 30
6.2 Lo que las pruebas no cubren 30
6.3 Verificar la calidad de las respuestas 31
CAPÍTULO 7. ESTADO FINAL, DEUDA TÉCNICA Y TRABAJO FUTURO 32
7.1 Lo que se entrega funcionando 32
7.2 Defectos conocidos y deuda técnica 32
7.3 Trabajo sugerido, en orden de prioridad 33
7.4 Decisiones pendientes del equipo 34
7.5 Riesgos para la continuidad y traspaso de accesos 34
CAPÍTULO 8. TUS PRIMERAS DOS SEMANAS 36
ANEXO A. VARIABLES DE ENTORNO 37
ANEXO B. GLOSARIO 38
ANEXO C. REFERENCIAS 39

ÍNDICE DE TABLAS

Tabla P.1: Control de versiones del documento. 7
Tabla 1.1: Resumen del estado final. 8
Tabla 1.2: Por dónde empezar. 9
Tabla 1.3: Documentos del proyecto y para qué sirven. 9
Tabla 2.1: Roles del sistema. 11
Tabla 2.2: Dentro y fuera del alcance (SC-001). 11
Tabla 2.3: Requisitos funcionales y su estado final. 12
Tabla 2.4: Requisitos no funcionales y restricciones. 12
Tabla 2.5: Parámetros del sistema y dónde se definen. 13
Tabla 2.6: Casos de uso del sistema. 13
Tabla 3.1: Carpetas del repositorio. 15
Tabla 3.2: Componentes, archivos y pruebas asociadas. 17
Tabla 3.3: Composición del acervo en la base vectorial (11/11/2026). 19
Tabla 3.4: Endpoints principales. 20
Tabla 3.5: Modelos generativos configurados. 21
Tabla 3.6: Controles de seguridad implementados. 21
Tabla 3.7: Páginas y scripts del frontend. 22
Tabla 3.8: Decisiones de diseño del apagado automático. 22
Tabla 3.9: Decisiones y sus motivos. 23
Tabla 4.1: Comprobaciones después de arrancar. 25
Tabla 5.1: Tareas de mantenimiento sugeridas. 26
Tabla 5.2: Operaciones sobre cuentas. 28
Tabla 5.3: Qué respaldar y cómo recuperarlo. 28
Tabla 5.4: Síntomas frecuentes en operación. 29
Tabla 6.1: Cobertura de la suite por archivo. 30
Tabla 6.2: Brechas de calidad conocidas. 30
Tabla 7.1: Fases técnicas terminadas. 32
Tabla 7.2: Registro de defectos conocidos (DC). 32
Tabla 7.3: Propuesta de trabajo para el relevo. 34
Tabla 7.4: Riesgos de continuidad 34

Tabla 7.5: Lista de verificación del traspaso. 35
Tabla 8.1: Plan de incorporación. 36
Tabla A.1: Variables del archivo .env. 37
Tabla B.1: Términos técnicos y del proyecto. 38
Tabla C.1: Referencias externas. 39

ÍNDICE DE FIGURAS

Figura 1: Arquitectura de despliegue de Nexus FI. 15
Figura 2: Mapa de módulos del código. 16
Figura 3: Flujo de una consulta en /api/chat. 18
Figura 4: Del documento oficial a la cita en el chat. 19
Figura 5: Modelo de datos (SQLite y LanceDB) 20

CONTROL DE VERSIONES DEL DOCUMENTO

Tabla P.1: Control de versiones del documento.

Versión	Fecha	Elaborado por	Revisado por	Descripción del cambio
1.0	11/11/2026	Equipo 404	Fernando Azuara Ibarra (Project Manager), pendiente de su visto bueno	Primera versión de la guía para quienes continúen el proyecto (servicio social). Estado del código y de la documentación al 11/11/2026.

CAPÍTULO 1. INTRODUCCIÓN Y CÓMO USAR ESTE DOCUMENTO

1.1 Propósito

Este documento le entrega el proyecto Nexus FI a quien lo continúe: alumnas y alumnos de servicio social, prestadores de prácticas o cualquier persona que herede el código. Reúne en un solo lugar lo que necesita saber para entender qué hace el sistema, por qué se construyó así, cómo ponerlo en marcha, cómo mantenerlo y qué falta por hacer.

Combina tres formatos de documentación de software, condensados a propósito: una especificación de requisitos (SRS, capítulo 2), un documento de diseño (SDD, capítulo 3) y una guía de transferencia y operación (capítulos 4 a 8). No sustituye a los entregables del curso (los Documentos Maestros de Planeación y de Ejecución); los resume y los lleva al estado final del proyecto.

1.2 Qué es Nexus FI

Nexus FI es un asistente virtual de la Facultad de Ingeniería de la UAEMéx que responde preguntas sobre trámites, servicio social, titulación, becas, horarios y normativa. Usa recuperación aumentada por generación (RAG): busca fragmentos relevantes en un acervo de documentos oficiales y le pide a un modelo de lenguaje que redacte la respuesta usando solo esos fragmentos, citando de qué documento y página salieron. Si el acervo no contiene la respuesta, el sistema lo dice en lugar de inventarla.

Está en producción como prueba piloto para Ingeniería en Computación (ICO) en https://d2j5rd06t9r4yq.cloudfront.net, con acceso por número de cuenta autorizado. Es un proyecto de la unidad de aprendizaje Administración de Proyectos Informáticos (2026-B), desarrollado por el Equipo 404.

1.3 Estado del proyecto al 11 de noviembre de 2026

Tabla 1.1: Resumen del estado final.

Elemento	Estado
Código	En la rama main del repositorio igream/Nexus-FI (PR 5 y 6 fusionados) y desplegado en la instancia EC2. Suite de 141 pruebas automáticas en verde.
Acervo	198 documentos y 3,340 fragmentos en la base vectorial: normativa universitaria, planes de estudio, becas, trámites, instalaciones, horarios de ICO y avisos.
Funciones terminadas	Historial cifrado por usuario, contexto conversacional, selector de modelo con cuotas, citas que abren el PDF original, tablero de usuario, panel de administración y apagado automático (fases F1 a F5 del plan de implementación).
Costos de operación	AWS: 0.00 USD (cubierto por el crédito de la cuenta). OpenAI: 0.16 USD en noviembre de 2026 al corte del 10/11.
Pendiente técnico principal	Etapa 2 de métricas de AWS en el panel de administración (ver sección 7.3).
Pendiente de decisión	Retención del historial y aviso de privacidad, tope diario del modelo Avanzado y tratamiento del acervo con información contradictoria (sección 7.4).
Defectos conocidos	Una respuesta errónea sobre las horas de servicio social en preguntas de seguimiento (DC-03) y varios puntos de seguridad y de operación (sección 7.2).

Elemento	Estado
	Las cifras desactualizadas de la interfaz y la tecla Enter ya están corregidas en el código, pendientes de desplegar.

1.4 Ruta de lectura según tu perfil

Tabla 1.2: Por dónde empezar.

Si vas a trabajar en…	Lee primero	Después
Cualquier parte (primer día)	Capítulo 1, sección 2.1 y capítulo 3 (3.1 a 3.4)	Capítulo 4 para poner el proyecto a funcionar en tu equipo
Backend y seguridad	Secciones 3.4, 3.6, 3.7 y 3.9	Capítulo 6 (pruebas) y los archivos de core/
Frontend	Secciones 3.10 y 2.7 (casos de uso)	Manual de usuario (docs/03_Cierre) para ver el comportamiento esperado
Acervo y calidad de respuestas	Secciones 3.5 y 5.3, y la sección 6.3	Documento de comparación de modelos y la sección 7.2
Infraestructura y costos	Secciones 3.8 y 5.2	Documento de Monitoreo y Control (docs/02_Ejecucion/Monitoreo_y_Control)
Gestión del proyecto y documentación	Capítulo 2 y sección 1.5	Documentos Maestros de Planeación (v7.0) y Ejecución (v1.1)

1.5 Documentos relacionados

Tabla 1.3: Documentos del proyecto y para qué sirven.

Documento	Ubicación en el repositorio	Para qué sirve
Documento Maestro de Planeación v7.0	docs/01_Planeacion/	Línea base: acta, alcance, requisitos, cronograma, riesgos, costos y ROI, con notas de ejecución.
Documento Maestro de Ejecución v1.1	docs/02_Ejecucion/Documento_Maestro/	Resultados reales, trazabilidad de requisitos, pruebas y anexos de los tres avances.
Documento y presentación de Monitoreo y Control	docs/02_Ejecucion/Monitoreo_y_Control/	Cómo se monitoreó, qué desvíos hubo y qué cambios se aprobaron (SC-001, SC-002).
Manual de usuario	docs/03_Cierre/	Cómo usan el asistente las personas usuarias, con capturas.
Plan de implementación	docs/PLAN_IMPLEMENTACION.md	Decisiones D1 a D7, fases F1 a F5 y bitácora técnica detallada.
Comparación de modelos	docs/02_Ejecucion/COMPARACION_MODELOS_2026-11-10_0150.md	Por qué se eligió gpt-6-luna como modelo Avanzado.
README y CLAUDE.md	Raíz del repositorio	Guía rápida de uso y contexto de traspaso

Documento	Ubicación en el repositorio	Para qué sirve
		para desarrolladores y agentes de código.

1.6 Convenciones

Los requisitos se numeran como en la tabla 1.7.1 del capítulo 2 del Documento Maestro de Planeación (RF01 a RF13 y RNF01 a RNF04). SC-001 y SC-002 son las solicitudes de cambio aprobadas; CP-xx son los casos de prueba y D-xx los hallazgos del Documento de Ejecución; F1 a F5 son las fases técnicas del plan de implementación. Las rutas de archivos se escriben desde la raíz del repositorio. Un glosario de términos está en el Anexo B.

CAPÍTULO 2. ESPECIFICACIÓN DE REQUISITOS (SRS CONDENSADO)

2.1 Descripción general

La información que necesita el alumnado de la Facultad (requisitos de servicio social, titulación, becas, horarios, a qué ventanilla acudir) está repartida en reglamentos, convocatorias, páginas web y avisos en redes sociales. Nexus FI la concentra y la hace consultable en lenguaje natural, con la fuente a la vista para que la persona pueda verificarla.

El sistema es una aplicación web progresiva (PWA) con un servicio de API en Python (FastAPI) que consulta una base vectorial local (LanceDB) y delega la redacción de respuestas a modelos de OpenAI. No se integra con los sistemas escolares: no ve calificaciones ni realiza trámites.

2.2 Usuarios y roles

Tabla 2.1: Roles del sistema.

Rol	Quién es	Qué puede hacer	Cómo se identifica
Alumno	Persona de ICO con número de cuenta en el padrón del piloto	Consultar, ver y borrar su historial, abrir las fuentes citadas, ver su tablero personal	Número de cuenta de 7 dígitos y contraseña propia
Administrador	Integrante del equipo con rol admin en el padrón	Lo anterior, más el panel de administración (consumo, costos, calidad) y el reinicio de registros	Igual que el alumno; el rol está en la cuenta autorizada
Visitante	Cualquier persona sin sesión	Solo ver la pantalla de acceso o la página de reposo del servidor	Ninguna

Otras partes interesadas: la Coordinación de ICO (Mtra. Beatriz Orozco Garduño, fuente de los horarios), la docente titular de la unidad de aprendizaje y la Dirección de la Facultad. Sus roles completos están en el Registro de Interesados del Documento Maestro de Planeación.

2.3 Alcance de la prueba piloto

Tabla 2.2: Dentro y fuera del alcance (SC-001).

Dentro del alcance	Fuera del alcance (por ahora)
Carrera de Ingeniería en Computación (ICO)	Otras carreras de la Facultad
Acceso con número de cuenta del padrón y contraseña propia	Control por segmento de red institucional (se retiró con la SC-001)
Consulta de 198 documentos con citas al PDF o al texto	Integración con sistemas de Control Escolar o servicios en línea
Dos modelos a elegir (Rápido y Avanzado) con cuotas por usuario	Enrutamiento automático por complejidad de la pregunta
Historial cifrado, tablero personal y panel de administración	Caché semántica de respuestas
Apagado automático de la instancia por inactividad	Disponibilidad 24/7 (RNF02 diferido por costo)
Interfaz responsiva con modo oscuro	Auditoría formal de accesibilidad WCAG 2.1 AA

2.4 Requisitos funcionales

Nota. La tabla compara cada requisito de la línea base con lo que existe hoy. El estado usa los mismos términos del Documento Maestro de Ejecución (tabla 3.10, trazabilidad). Dentro del código, el umbral de similitud aparece comentado como «RF13»; en el Documento Maestro corresponde al RF11.

Tabla 2.3: Requisitos funcionales y su estado final.

ID	Requisito	Cómo se cumple hoy	Estado
RF01	Consulta de normativa universitaria	Chat RAG con reglamentos citados, historial y contexto de la conversación	Parcial
RF02	Información de trámites académicos	Respuestas sobre reinscripción, bajas, servicio social y prácticas; faltan huecos en titulación	Parcial
RF03	Becas y convocatorias	Convocatorias 2026B y reglamento de becas en el acervo	Cumplido
RF04	Localización física	Aulas por grupo en los horarios de ICO; sin caso para ubicar dependencias	Parcial
RF05	Horarios de asesoría y directorio	Horarios de clases por grupo y remisión a la Coordinación	Parcial
RF06	Enrutamiento semántico dual LLM	La persona elige Rápido (gpt-4o-mini) o Avanzado (gpt-6-luna); no hay enrutador automático	Cumplido con variación
RF07	Interfaz webchat responsiva	PWA verde y oro, modo oscuro y diseño para celular	Cumplido
RF08	Pipeline de ingesta y vectorización	Paquete nexus_ingestion; fragmentos de 132 a 674 tokens con solapamiento del 15 % (previstos 500 a 800)	Cumplido con variación
RF09	Citación obligatoria	Cada respuesta lista archivo, categoría, artículo y relevancia; cada cita abre el PDF original en su página o el visor de texto	Cumplido
RF10	Telemetría y analítica	Tablero de usuario y panel de administración con datos reales; CloudWatch solo se usa para el apagado automático	Cumplido con variación
RF11	Umbral de similitud calibrado	Umbral 0.52 y piso 0.30 para términos poco comunes	Cumplido
RF12	Control de consumo	20 por hora y 60 por día (Rápido) y 5 por hora (Avanzado), por usuario; sin caché semántica	Cumplido con cambio
RF13	Abstención cortés	Mensaje de respaldo que remite al área presencial cuando no hay fuentes	Cumplido

2.5 Requisitos no funcionales

Tabla 2.4: Requisitos no funcionales y restricciones.

ID	Requisito	Situación al 11/11/2026	Estado
RNF01	Latencia de 3.5 s o menos en el 95 % de las consultas	La búsqueda vectorial tarda menos de 700 ms; el panel de administración ya calcula p50 y p95 de la respuesta completa, pero falta fijar la medición formal contra los 3.5 s	Por medir
RNF02	Disponibilidad del 99.5 %	La instancia se apaga sola por inactividad y se enciende en menos de 2 minutos; no se mide disponibilidad 24/7	Diferido
RNF03	Seguridad y protección de datos	Control perimetral sustituido por inicio de sesión (SC-001); datos cifrados, contraseñas con hash, claves segregadas	Cumplido con cambio

ID	Requisito	Situación al 11/11/2026	Estado
RNF04	Usabilidad y accesibilidad	Interfaz responsiva y modo oscuro verificados; sin auditoría formal WCAG 2.1 AA	Parcial
Restricción	Presupuesto	Tope de infraestructura de 10 USD al mes (GP-09); operar 24/7 costaría 21.23 USD, por eso el apagado automático	En vigor
Restricción	Idioma y convenciones	Código, comentarios, commits y documentos en español	En vigor

2.6 Reglas de negocio y parámetros vigentes

Estos valores están en el código; si los cambias, actualiza también las pruebas y la documentación.

Tabla 2.5: Parámetros del sistema y dónde se definen.

Regla	Valor	Dónde vive
Número de cuenta	Exactamente 7 dígitos y presente en el padrón (cuentas_autorizadas)	core/auth/routes.py, core/auth/store.py
Contraseña	Mínimo 8 caracteres y máximo 72 bytes (límite de bcrypt)	core/auth/routes.py
Sesión	Token JWT de 8 horas; cerrar sesión lo revoca	core/auth/tokens.py
Intentos fallidos	5 por cuenta en 15 minutos y luego error 429	core/auth/routes.py
Cuota del modelo Rápido	20 consultas por hora y 60 por día, por usuario	core/chat/modelos.py (MODELOS)
Cuota del modelo Avanzado	5 consultas por hora, sin tope diario (por decidir)	core/chat/modelos.py (MODELOS)
Tope de salida	1,200 tokens (Rápido) y 6,000 incluyendo razonamiento (Avanzado)	core/chat/modelos.py (MODELOS)
Umbral de similitud	0.52; piso 0.30 si el fragmento contiene tal cual un término poco común de la pregunta	nexus_ingestion/vector_store.py
Fragmentos por consulta	top_k = 4 por defecto (de 1 a 10)	backend/app.py (ChatRequest)
Contexto de la conversación	Últimos 3 pares pregunta-respuesta, hasta unos 1,500 tokens estimados	core/chat/contexto.py
Longitud de la pregunta	500 caracteres (límite del cuadro de texto)	frontend/index.html
Enlace al PDF citado	Firmado con HMAC y válido 10 minutos	core/documentos/routes.py
Apagado automático	NetworkIn menor a 8,000 bytes en 3 periodos de 5 minutos	infra/f5/apagado.yaml

2.7 Casos de uso principales

Tabla 2.6: Casos de uso del sistema.

ID	Caso de uso	Flujo principal	Excepciones
CU-01	Registrarse	El alumno elige carrera, escribe su cuenta y crea su contraseña; el sistema guarda solo el hash	403 cuenta fuera del padrón; 409 ya registrada; 422 datos inválidos
CU-02	Iniciar sesión	Cuenta y contraseña correctas devuelven un token de 8 horas	401 datos incorrectos; 429 tras 5 intentos fallidos
CU-03	Consultar al asistente	La persona escribe una pregunta y elige el modelo; recibe una respuesta con citas	401 sin sesión; 429 cuota agotada; 503 modelo sin clave; sin fragmentos: mensaje de abstención

ID	Caso de uso	Flujo principal	Excepciones
CU-04	Hacer una pregunta de seguimiento	Dentro de la misma conversación, el sistema reescribe la pregunta con el historial antes de buscar	Si la reescritura falla, se usa la pregunta original
CU-05	Abrir la fuente citada	La cita pide un enlace firmado y abre el PDF en la página citada o el visor de texto	Enlace vencido o inválido: 403; sin PDF en el servidor: texto procesado
CU-06	Elegir el modelo	Rápido o Avanzado, cada uno con su cuota independiente	Modelo sin clave configurada: no disponible
CU-07	Gestionar el historial	Listar, abrir, renombrar y borrar conversaciones propias	Una conversación ajena responde 404
CU-08	Ver el tablero personal	Consultas, cuotas, temas y latencia de los últimos 7 o 30 días	401 sin sesión
CU-09	Administrar	El administrador consulta el panel, lista cuentas registradas y reinicia un registro	403 para alumnos; no puede reiniciar su propia cuenta
CU-10	Encender el servidor en reposo	La página de reposo llama a la Lambda, que enciende la instancia; la página abre la aplicación cuando responde	Si tarda más de 8 minutos, la página lo indica

2.8 Supuestos, restricciones y dependencias

Acervo. El acervo fue curado por el equipo para la prueba piloto de ICO y su vigencia depende de que alguien lo actualice; el sistema no sabe si un reglamento cambió.

Servicios externos. Todas las respuestas dependen de la API de OpenAI (embeddings y generación). Si el servicio falla o cambia un modelo, la aplicación responde con el texto del fragmento principal como respaldo, pero sin redacción.

Padrón. El padrón de cuentas autorizadas lo carga el administrador a partir de un archivo que mantiene el equipo; no existe integración con Servicios Escolares y los oficios de autorización se asumieron para el piloto.

Nube. La infraestructura se aloja en una cuenta de AWS con plan gratuito y crédito limitado. La instancia no tiene dirección IP fija.

CAPÍTULO 3. DISEÑO DEL SOFTWARE (SDD CONDENSADO)

3.1 Vista general de la arquitectura

El navegador entra por CloudFront, que reenvía a una instancia EC2 donde Docker Compose ejecuta dos contenedores: Nginx (proxy) y el backend FastAPI. El backend lee y escribe en el volumen data/ (base de usuarios SQLite, base vectorial LanceDB y PDF originales) y llama a OpenAI. Si la instancia está apagada, CloudFront muestra una página de reposo guardada en S3 cuyo botón enciende la instancia mediante una función Lambda.

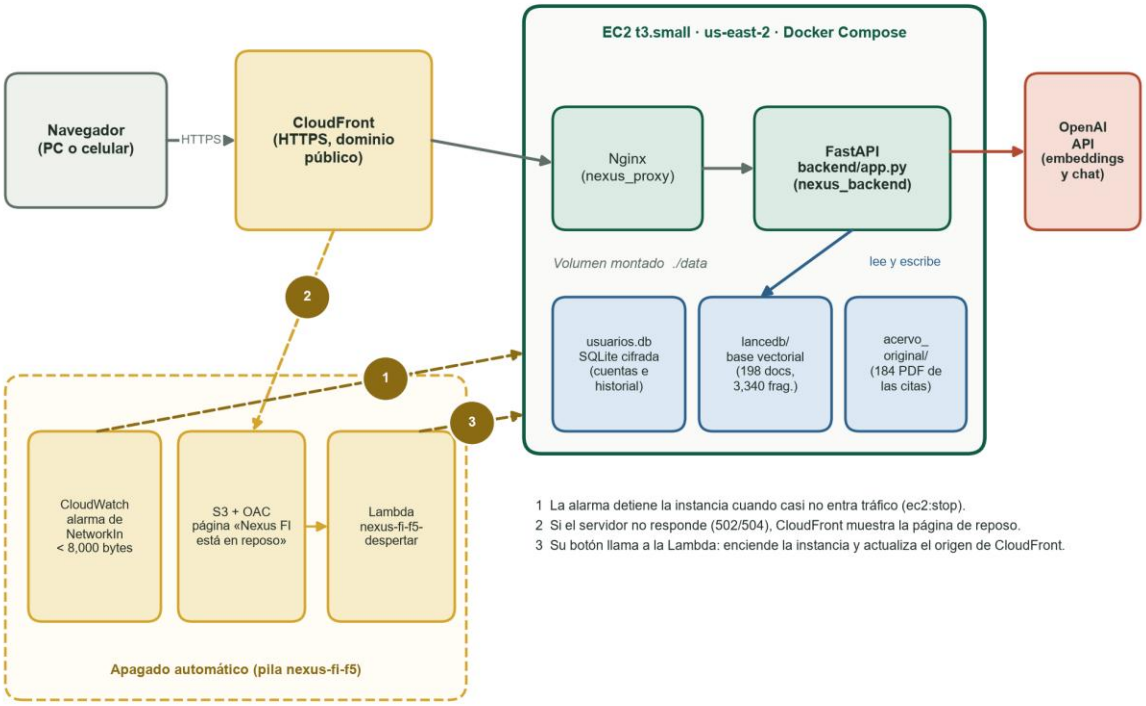


Figura 1: Arquitectura de despliegue de Nexus FI.

3.2 Estructura del repositorio

Tabla 3.1: Carpetas del repositorio.

Carpeta o archivo	Contenido	En Git
backend/app.py	Aplicación FastAPI: /api/chat, métricas, salud y páginas estáticas	Sí
core/	Módulos de dominio: auth, chat, documentos, security y metricas	Sí
nexus_ingestion/	Paquete de ingesta: extractores, clasificador, segmentador, embeddings y base vectorial	Sí
frontend/	Páginas HTML, CSS y JavaScript de la PWA	Sí

Carpeta o archivo	Contenido	En Git
scripts/	Utilidades: procesar acervo, vectorizar, comparar modelos, precargar cuentas y desplegar F5	Sí
infra/f5/	Plantilla CloudFormation, Lambda de encendido y página de reposo	Sí
nginx/, Dockerfile, docker-compose.yml	Proxy y contenedores del despliegue	Sí
tests/	141 pruebas con pytest	Sí
Procesados/	Acervo ya convertido a Markdown y JSON con metadatos, y el corpus de fragmentos	Sí
fuentes_piloto/	Horarios, avisos y capítulos estudiantiles de ICO en Markdown, con su inventario	Sí
docs/	Documentos del curso, plan de implementación y manuales	Sí
Pre Procesados/	PDF y HTML originales del acervo (unos 243 MB)	No
data/	lancedb/, usuarios.db y acervo_original/ (se copian a mano)	No
.env	Claves y secretos (plantilla en .env.example)	No
Local/, scratch/	Material interno del equipo y scripts temporales	No

3.3 Componentes

Los módulos están organizados por responsabilidad. Cada router de FastAPI vive en su paquete de core/ y se registra en backend/app.py.

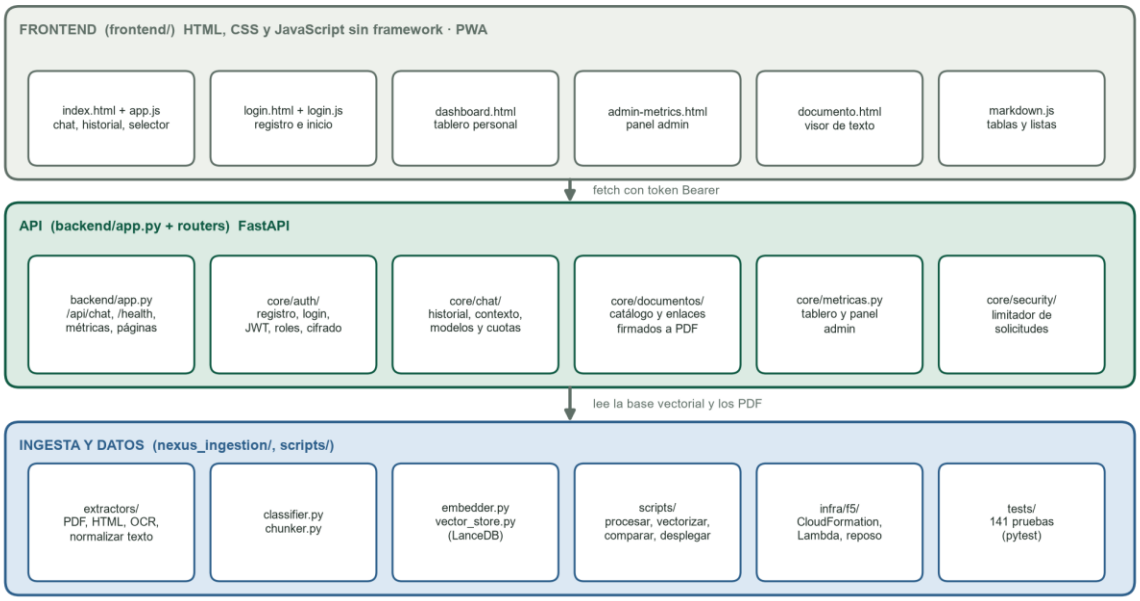


Figura 2: Mapa de módulos del código.

Tabla 3.2: Componentes, archivos y pruebas asociadas.

Componente	Archivos	Responsabilidad	Pruebas
API principal	backend/app.py	Orquesta el flujo RAG en /api/chat, expone salud, métricas y páginas; monta CORS, limitador, sesión y cabecera no-cache	test_modelos, test_contexto, test_cache_frontend
Autenticación	core/auth/	Registro, inicio y cierre de sesión, roles, cifrado de datos personales y tokens	test_auth
Historial y contexto	core/chat/store.py, routes.py, contexto.py	Conversaciones y mensajes cifrados, últimos turnos y reescritura de preguntas	test_conversaciones, test_contexto
Modelos y cuotas	core/chat/modelos.py	Tabla única MODELOS: claves, tarifas, topes, cuotas y parámetros por modelo	test_modelos
Citas consultables	core/documentos/	Catálogo del acervo y enlaces firmados al PDF original	test_documentos
Métricas	core/metricas.py	Cálculo del tablero de usuario y del panel de administración desde la tabla mensajes	test_metricas
Limitador	core/security/rate_limiter.py	Límite en memoria para las rutas no exentas	test_rate_limiter
Búsqueda vectorial	nexus_ingestion/vector_store.py	Consulta en LanceDB con umbral, términos poco comunes y filtro de duplicados	test_busqueda_terminos
Ingesta	nexus_ingestion/ (pipeline, chunker, classifier, embedder)	Extrae, clasifica, segmenta y vectoriza documentos	Sin pruebas propias
Infraestructura F5	infra/f5/, scripts/f5_desplegar.py	Apagado automático, encendido y página de reposo	test_f5
Frontend	frontend/	Chat, acceso, tablero, panel de administración y visor de texto	Sin pruebas automáticas

3.4 Flujo de una consulta

Cada pregunta recorre el flujo de la figura 3. Los pasos 3 y 4 llaman a OpenAI; el paso 5 usa la base vectorial local; los pasos 2 y 9 usan la base SQLite. La búsqueda se hace con la pregunta reescrita (si hubo historial), pero el modelo que redacta recibe la pregunta original junto con los turnos previos.

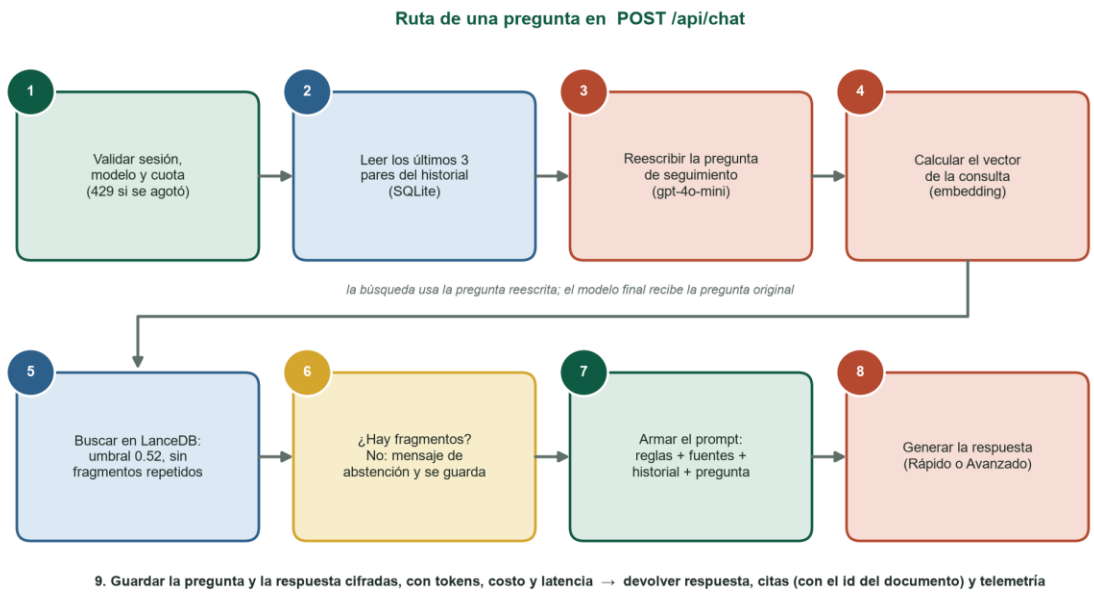


Figura 3: Flujo de una consulta en /api/chat.

El prompt de sistema obliga al modelo a responder solo con el contexto recuperado, a citar el documento fuente, a no inventar procedimientos, a mencionar el área presencial cuando haya trámites, a no afirmar semestres de una materia sin fuente explícita (regla 5, agregada por un mapa curricular revuelto que causaba errores) y a presentar tablas en Markdown (regla 6). Cada modelo agrega su propio estilo (concisión o detalle). El prompt está en backend/app.py, dentro de chat_endpoint.

Casos sin respuesta del modelo. Si ningún fragmento supera el umbral, no se llama al modelo: se devuelve el mensaje de abstención (RF13), se guarda el turno con modelo «rule-based fallback» y no se cobra generación. Si el modelo falla, se responde con el texto del fragmento principal (síntesis directa).

3.5 Acervo, ingesta y base vectorial

El acervo se transforma en tres etapas: extracción y limpieza de cada documento, clasificación con metadatos y segmentación en fragmentos de unos 650 tokens con solape de 100, conservando el artículo y la página de origen; después se calculan los embeddings (text-embedding-3-small, 1,536 dimensiones) y se guardan en la tabla nexus_documents de LanceDB.

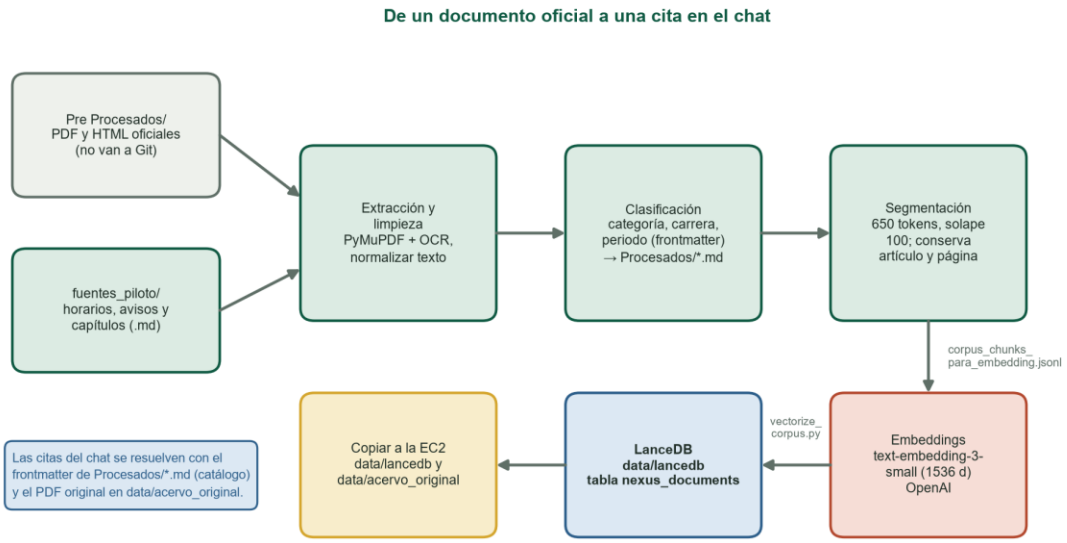


Figura 4: Del documento oficial a la cita en el chat.

Tabla 3.3: Composición del acervo en la base vectorial (11/11/2026).

Categoría	Documentos	Fragmentos	Contenido típico
normativa	89	1,864	Estatuto, reglamentos, lineamientos, protocolos y acuerdos de la UAEMéx
planes_estudio	65	703	Planes y temarios de ICO
instalaciones_servicios	3	366	Control Escolar y servicios de la Facultad
becas	20	196	Convocatorias 2026B y reglamento de becas
horarios	10	113	Horarios de ICO por semestre (fuentes piloto)
tramites	9	89	Guías de trámites
vida_estudiantil	1	5	Capítulos estudiantiles IEEE
avisos	1	4	Avisos de redes sociales de la Facultad
Total	198	3,340	

Cada documento procesado en Procesados/ lleva un encabezado (frontmatter) con id, título, categoría, carrera, periodo y archivo fuente. Ese encabezado alimenta el catálogo de citas: sin volver a calcular embeddings, el sistema sabe qué PDF original corresponde a cada cita y lo abre en la página citada.

3.6 Modelo de datos

Los datos de usuarios e historial viven en una sola base SQLite (data/usuarios.db); los fragmentos del acervo, en LanceDB. Los campos sensibles se guardan cifrados con Fernet; el número de cuenta, además, tiene una huella HMAC-SHA256 para poder buscarlo sin guardarlo en claro.

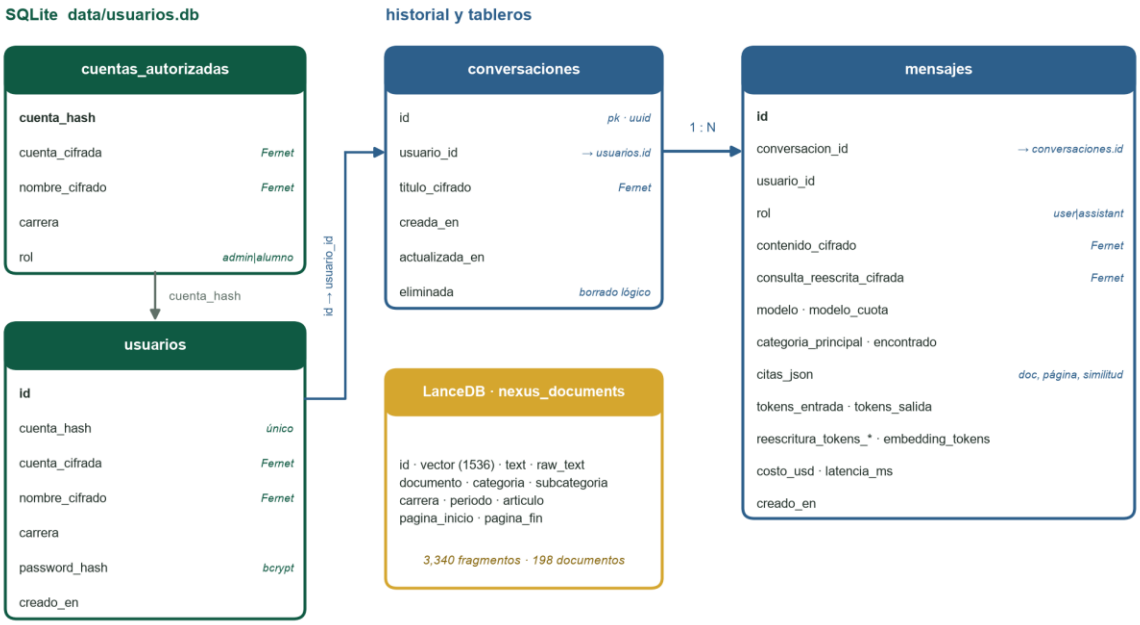


Figura 5: Modelo de datos (SQLite y LanceDB).

Las tablas se crean y migran solas al iniciar la aplicación (init_db): las columnas nuevas se agregan con ALTER TABLE sin perder datos. El borrado de conversaciones es lógico (eliminada = 1) para que las cuotas y los tableros sigan cuadrando. Cada respuesta del asistente es una fila en mensajes con su modelo, tokens, costo y latencia; de ahí salen las cuotas, el tablero y el panel de administración.

3.7 Interfaz de programación (API)

La documentación interactiva (Swagger) está en /docs de cualquier instancia en marcha. Todas las rutas de /api, excepto las públicas, requieren la cabecera Authorization: Bearer con el token de sesión.

Tabla 3.4: Endpoints principales.

Método y ruta	Acceso	Descripción
GET /health	Público	Salud simple para balanceadores y para la página de reposo
GET /api/health	Público	Estado del servicio, de la base vectorial y de las claves configuradas
GET /api/stats	Público	Datos institucionales y del corpus (la cuenta de documentos sale de la base vectorial)
GET /api/session/info	Sesión opcional	Usuario, rol y cuotas restantes por modelo
POST /api/auth/registro	Público	Crea la contraseña de una cuenta del padrón
POST /api/auth/login	Público	Devuelve token, carrera, nombre y rol
POST /api/auth/logout	Sesión	Revoca el token
POST /api/chat	Sesión	Consulta RAG: pregunta, modelo, conversation_id y top_k opcionales
GET /api/conversaciones y /{id}	Sesión	Lista y detalle del historial propio
PATCH y DELETE /api/conversaciones/{id}	Sesión	Renombrar o borrar (lógico) una conversación propia
POST /api/documentos/{id}/enlace	Sesión	Enlace firmado al PDF o al visor de texto

Método y ruta	Acceso	Descripción
GET /api/documentos/{id}/archivo	Enlace firmado	PDF original en línea
GET /api/documentos/{id}/texto	Sesión	Texto procesado para el visor
GET /api/v1/metrics/user-dashboard	Sesión	Tablero personal (parámetro dias = 7 o 30)
GET /api/v1/admin/metrics	Administrador	Consumo, costo, usuarios activos y calidad
GET /api/auth/admin/usuarios	Administrador	Cuentas que ya crearon contraseña
POST /api/auth/admin/reiniciar-registro	Administrador	Borra la contraseña de una cuenta para que se registre de nuevo

Las páginas se sirven desde la misma aplicación: / (chat), /login, /dashboard, /admin-metrics y /documento.

3.8 Modelos y cuotas

Tabla 3.5: Modelos generativos configurados.

Dato	Rápido	Avanzado
Modelo de OpenAI	gpt-4o-mini	gpt-6-luna (razonamiento con esfuerzo bajo)
Precio por millón de tokens (entrada y salida)	0.15 y 0.60 USD	0.10 y 0.50 USD
Tope de salida	1,200 tokens	6,000 tokens (incluye el razonamiento)
Cuota por usuario	20 por hora y 60 por día	5 por hora, sin tope diario
Variable de entorno de la clave	OPENAI_API_KEY_CHAT_4O_MINI	OPENAI_API_KEY_GPT6_LUNA
Uso adicional	Reescribe las preguntas de seguimiento para cualquier modelo	Solo cuando la persona lo elige

Todo lo que depende del modelo sale de la tabla MODELOS en core/chat/modelos.py: identificador de API, clave, tarifas, topes, cuotas y parámetros admitidos. gpt-6-luna es un modelo de razonamiento: no acepta max_tokens (usa max_completion_tokens) y solo admite temperature con reasoning_effort igual a none. La comparación de 20 preguntas del 10/11/2026 dio 17 de 20 aciertos en los tres modelos probados, y gpt-6-luna resultó el más económico (unos 0.00026 USD por consulta), por lo que se retiró gpt-5.6-luna.

Las cuotas se cuentan desde la tabla mensajes (columna modelo_cuota), no en memoria, así que sobreviven a los reinicios. Abrir el historial o las fuentes no consume cuota.

3.9 Seguridad

Tabla 3.6: Controles de seguridad implementados.

Control	Implementación
Datos personales	Número de cuenta y nombre cifrados con Fernet; número de cuenta buscable por huella HMAC-SHA256; contraseñas solo como hash bcrypt
Sesión	JWT HS256 de 8 horas con solo el id interno; el cierre de sesión revoca el token (lista en memoria)
Fuerza bruta	5 intentos fallidos por cuenta en 15 minutos; el tiempo de respuesta se iguala cuando la cuenta no existe
Roles	Los endpoints de administración responden 401 sin sesión y 403 a los alumnos

Control	Implementación
Aislamiento	Una conversación ajena o borrada responde 404, igual que una inexistente
Historial	Título, texto y consulta reescrita guardados cifrados
Documentos	Solo se aceptan identificadores del catálogo; las rutas deben quedar dentro de la carpeta de originales; los HTML originales no se sirven
Claves de OpenAI	Segregadas por servicio (embeddings, Rápido y Avanzado) para medir el consumo de cada una
Secretos en Git	El .env y data/ están ignorados; python main.py --audit y scripts/security_vault.py detectan secretos y instalan un gancho previo a commit
Registros	La bitácora de administración usa ids internos, nunca números de cuenta ni nombres

Las limitaciones conocidas de seguridad están en la sección 7.2 (DC-04 a DC-06).

3.10 Frontend

El frontend es HTML, CSS y JavaScript sin framework, servido por la propia API. El token se guarda en localStorage y cada llamada lo envía en la cabecera Authorization; si la API responde 401, la sesión se borra y se vuelve a /login. markdown.js convierte las respuestas (listas y tablas) a HTML. service-worker.js y manifest.webmanifest permiten instalar la PWA. Los archivos se revalidan en cada carga (cabecera no-cache con respuestas 304) para no mostrar versiones viejas.

Tabla 3.7: Páginas y scripts del frontend.

Archivo	Función
index.html y app.js	Chat, historial, selector de modelo, cuotas, citas y herramientas de administrador
login.html y login.js	Registro e inicio de sesión
dashboard.html	Tablero personal con gráficas de Chart.js
admin-metrics.html	Panel de administración
documento.html y documento.js	Visor de texto para fuentes sin PDF
markdown.js	Conversión de Markdown con tablas, compartida por el chat y el visor
styles.css	Estilos verde y oro, modo oscuro y diseño móvil

3.11 Infraestructura y apagado automático

La producción corre en una sola instancia EC2 t3.small en la región us-east-2, detrás de CloudFront. Para cuidar el presupuesto, la instancia se apaga sola y se enciende bajo demanda. Todo está definido en infra/f5/apagado.yaml (CloudFormation) y se despliega con scripts/f5_desplegar.py.

Tabla 3.8: Decisiones de diseño del apagado automático.

Decisión	Motivo
Alarma sobre NetworkIn menor a 8,000 bytes en 3 periodos de 5 minutos	El trabajo pesado ocurre en OpenAI, así que la CPU casi no sube con gente usando la app; una consulta deja unos 11 KB de red. Umbral calibrado con 7 días de datos
Acción nativa ec2:stop de CloudWatch	No requiere servicios externos (decisión D7); una alarma con métrica matemática no puede ejecutar acciones de EC2
Página de reposo solo para errores 502 y 504	La aplicación responde 503 a propósito (modelo sin clave, inicio de sesión sin configurar) y CloudFront convertiría esas respuestas en la página

Decisión	Motivo
Lambda de encendido idempotente con Function URL y token	Enciende la instancia, espera y actualiza el origen de CloudFront con el nuevo DNS; el token no es secreto, solo frena escáneres
Origen EC2 con 4 s de espera y 1 intento	Para que la página de reposo aparezca rápido
Sin IP elástica	Ahorra unos 3.6 USD al mes; la Lambda actualiza el origen en cada encendido

Medido el 10/11/2026: la instancia se detuvo sola, la página de reposo apareció en todas las rutas y el botón la volvió a encender en menos de 2 minutos.

3.12 Decisiones de diseño clave

Tabla 3.9: Decisiones y sus motivos.

Decisión	Motivo	Consecuencia
SQLite en un volumen, sin servicio de base de datos gestionado	Costo cero y simplicidad para un piloto con pocos usuarios	Un solo proceso escribe; el respaldo es manual (sección 5.8)
LanceDB local en lugar de un servicio vectorial	Sin servidor adicional; la base pesa unos 28 MB	Hay que copiar data/lancedb a la instancia cuando cambia el acervo
El usuario elige el modelo (D1)	Evita un enrutador que clasifique la complejidad y dé resultados difíciles de explicar	Cada modelo tiene su propia cuota
Cuotas contadas desde la base	Sobreviven a los reinicios y no dependen de memoria	Cada consulta consulta mensajes por usuario y modelo
Reescritura de la pregunta solo con historial	Las preguntas como «¿y el plazo?» no se pueden buscar solas	Una llamada extra y barata a gpt-4o-mini por seguimiento
Citas por catálogo y no por regenerar el acervo	No fue necesario recalcular embeddings ni modificar los fragmentos	El frontmatter de Procesados/ debe conservar archivo_fuente
Acceso por número de cuenta precargado (SC-001)	No hay padrón institucional ni segmento de red utilizable	El padrón lo mantiene el administrador

CAPÍTULO 4. PUESTA EN MARCHA EN TU EQUIPO

Esta guía deja el sistema funcionando en tu computadora para desarrollar y probar. Necesitas Python 3.11 (la imagen de Docker usa esa versión; hay soporte desde 3.10) y Git. El reconocimiento óptico (OCR) con RapidOCR solo existe para versiones anteriores a Python 3.12 y únicamente se necesita si vas a reprocesar PDF escaneados.

4.1 Obtener el código e instalar

Paso 1. Clona el repositorio y entra a la carpeta.

Paso 2. Crea y activa un entorno virtual.

Paso 3. Instala las dependencias.

```
git clone https://github.com/igream/Nexus-FI.git
cd Nexus-FI
python -m venv .venv
.venv\Scripts\activate          (Linux o macOS: source .venv/bin/activate)
pip install -r requirements.txt
```

4.2 Configurar el archivo .env

Copia .env.example como .env y completa los valores. Nunca subas el .env a Git. Las tres claves de OpenAI y los datos del acervo te los debe entregar el equipo saliente por un medio seguro (sección 7.5). Para probar solo el modelo Rápido basta una clave en OPENAI_API_KEY (sirve para embeddings y para gpt-4o-mini); el modelo Avanzado necesita OPENAI_API_KEY_GPT6_LUNA.

Genera tus propios secretos de sesión y cifrado con estos comandos y pégalos en AUTH_JWT_SECRET, CUENTA_HMAC_KEY y CUENTA_FERNET_KEY:

```
python -c "import secrets; print(secrets.token_urlsafe(32))"
python -c "from cryptography.fernet import Fernet;
print(Fernet.generate_key().decode())"
```

Cuidado. Si cambias CUENTA_HMAC_KEY o CUENTA_FERNET_KEY después de crear cuentas, la base de usuarios existente deja de servir. En un equipo nuevo, usa claves nuevas y una base nueva; no mezcles las de producción. El Anexo A explica cada variable.

4.3 Base vectorial y documentos originales

La base vectorial (data/lancedb, unos 28 MB) no está en Git. Hay dos caminos: pedirla al equipo saliente y copiarla a data/lancedb, o regenerarla desde Procesados/ con scripts/vectorize_corpus.py (sección 5.3), lo que cuesta unos 0.04 USD de embeddings (cerca de 2 millones de tokens), pero consume tu clave de OpenAI.

Los PDF originales (carpeta Pre Procesados/, fuera de Git) solo hacen falta para que las citas abran el PDF en la página citada. Sin ellos, el sistema cae al texto procesado y todo funciona. Si los tienes, scripts/preparar_acervo_original.py los copia a data/acervo_original.

4.4 Crear cuentas de prueba y arrancar

```
python scripts/precargar_cuentas.py --ficticias
python main.py --serve --dev
```

El primer comando carga las cuentas ficticias 1000001 a 1000009 (rol alumno). El segundo inicia el servidor en http://127.0.0.1:8000 con el límite de consultas apagado (--dev). Abre esa dirección, registra una cuenta ficticia (la contraseña la inventas tú) e inicia sesión. Para probar el panel de administración necesitas una cuenta con rol admin, que se carga con un CSV (sección 5.6).

4.5 Comprobar que todo funciona

Tabla 4.1: Comprobaciones después de arrancar.

Comprobación	Cómo	Resultado esperado
El servidor responde	Abrir http://127.0.0.1:8000/health	status healthy
La base vectorial está cargada	Abrir /api/health y mirar vector_database	online y total_vectors igual a 3,340 con el acervo completo
Las claves están configuradas	Mirar segregated_api_keys en /api/health	configured en true para las claves que tengas
El chat responde con citas	Iniciar sesión y preguntar «¿Cuántas horas de servicio social debo cubrir?»	Respuesta con 480 horas y el Reglamento del Servicio Social como fuente
Las pruebas pasan	python -m pytest tests -q	141 passed

Otros comandos útiles: python main.py --telemetry (diagnóstico de claves y base vectorial), python main.py --search «pregunta» (búsqueda semántica sin servidor) y python main.py --audit (busca secretos antes de un commit).

CAPÍTULO 5. OPERACIÓN Y MANTENIMIENTO

5.1 Tareas recurrentes

Tabla 5.1: Tareas de mantenimiento sugeridas.

Tarea	Cuándo	Cómo
Revisar costos y consumo	Semanal	Panel de administración (costo por modelo) y panel de uso de OpenAI; AWS en Billing
Revisar preguntas sin resultado	Semanal	Panel de administración: sirven para ampliar el acervo
Respaldar usuarios.db y .env	Antes de cada despliegue y mensual	Sección 5.8
Actualizar el acervo	Cuando cambie normativa, convocatorias u horarios	Sección 5.3
Actualizar horarios del semestre	Cada periodo escolar	Editar fuentes_piloto/ y actualizar su INVENTARIO.md; después, sección 5.3
Cargar o dar de baja cuentas	Cuando cambie el padrón	Sección 5.6
Verificar que las respuestas sigan siendo correctas	Después de cambiar acervo, prompt o modelo	Sección 6.3
Revisar el crédito de AWS	Mensual	Billing de AWS; el crédito es finito

5.2 Despliegue en la instancia EC2

La instancia no tiene IP fija: consulta la IP pública actual en la consola de EC2 (región us-east-2) cada vez que la enciendas. Si está detenida, enciéndela desde la página de reposo o desde la consola. Necesitas la llave SSH del proyecto (archivo .pem), que guarda el equipo.

Paso 1. Entra por SSH. La aplicación está en ~/Nexus-FI.

Paso 2. Respalda la base de usuarios y el .env en ~/respaldos/.

Paso 3. Trae los cambios; solo se permite avance rápido sobre main.

Paso 4. Reconstruye y levanta los contenedores.

Paso 5. Comprueba la salud por CloudFront.

```
ssh -i <llave>.pem ubuntu@<IP-actual>
cd ~/Nexus-FI
mkdir -p ~/respaldos && cp data/usuarios.db ~/respaldos/usuarios_$(date +%F).db
cp .env ~/respaldos/env_$(date +%F)
git pull --ff-only
sudo docker compose up -d --build
curl -s https://d2j5rd06t9r4yq.cloudfront.net/health
```

Las migraciones de la base son automáticas y sin pérdida de datos. Si cambiaste el acervo, copia también data/lancedb y data/acervo_original (sección 5.3) y reinicia solo el backend con sudo docker compose restart backend, porque el catálogo de citas y el conteo de documentos se leen al arrancar.

Regla del proyecto. Antes de cambios en producción, en AWS o en el acervo, confirma con el responsable del proyecto. No reescribas el historial publicado de Git: los entregables del curso citan commits concretos.

5.3 Agregar o actualizar documentos del acervo

Paso 1. Coloca el PDF, HTML o archivo Markdown en la carpeta de Pre Procesados/ que corresponda (o en fuentes_piloto/ si es una fuente piloto limpia).

Paso 2. Ejecuta scripts/process_to_procesados.py para generar los Markdown y JSON en Procesados/, el corpus de fragmentos (corpus_chunks_para_embedding.jsonl) y el manifiesto. Revisa con git diff qué cambió.

Paso 3. Vectoriza: para actualizar solo algunas categorías usa el modo upsert; para reconstruir toda la base, el modo overwrite (el predeterminado).

Paso 4. Si el documento es un PDF, copia los originales con scripts/preparar_acervo_original.py.

Paso 5. Prueba una búsqueda con python main.py --search «pregunta» y revisa que el documento nuevo aparezca con su página y artículo.

Paso 6. Copia data/lancedb y data/acervo_original a la instancia y reinicia el backend (sección 5.2).

```
python scripts/process_to_procesados.py
python scripts/vectorize_corpus.py --mode upsert --categorias horarios,avisos
python scripts/preparar_acervo_original.py
scp -r data/lancedb data/acervo_original ubuntu@<IP-actual>:~/Nexus-FI/data/
```

Para retirar un documento del acervo, usa overwrite, que reconstruye la tabla completa a partir del corpus. Antes de reprocesar, revisa que no se pierdan correcciones manuales hechas en Procesados/. Si agregas una categoría nueva, agrégala también al clasificador (nexus_ingestion/classifier.py). Documenta cada fuente nueva en fuentes_piloto/INVENTARIO.md con su origen, responsable y fecha de la información.

5.4 Cambiar modelos o cuotas

Edita la tabla MODELOS en core/chat/modelos.py (identificador de API, clave, tarifas, cuotas y parámetros), agrega la variable de entorno de la clave al .env de la instancia y ajusta tests/test_modelos.py. Para agregar un modelo al selector, usa en_selector en verdadero; el frontend lee las cuotas de /api/session/info. Antes de adoptar un modelo nuevo, compáralo con scripts/comparar_modelos.py y verifica sus precios y parámetros en la documentación de OpenAI el mismo día: cambian.

Cuidado. Un modelo de razonamiento como gpt-6-luna no acepta max_tokens (usa max_completion_tokens) y solo admite temperature con reasoning_effort igual a none; así se verificó con llamadas reales el 10/11/2026. Usa siempre modelos.parametros_llamada() en lugar de armar los argumentos a mano.

5.5 Habilitar otra carrera

La carrera del piloto está definida en el diccionario CARRERAS de core/auth/store.py. Para abrir otra: agrégala ahí y en la lista de la pantalla de registro (frontend/login.html), carga a su padrón con esa carrera, y agrega documentos con ese valor en el campo carrera (el clasificador lo asigna según

la ruta). La búsqueda no filtra por carrera por defecto; la categoría y la carrera solo orientan al modelo. Evalúa si necesitas filtrar para evitar mezclar planes de estudio.

5.6 Gestión de cuentas

Tabla 5.2: Operaciones sobre cuentas.

Operación	Cómo
Cargar el padrón	python scripts/precargar_cuentas.py --csv <ruta fuera del repositorio>. El CSV lleva numero_cuenta, nombre, carrera y rol (nombre y rol son opcionales). Nunca guardes el CSV dentro del proyecto ni lo subas a GitHub
Crear cuentas de prueba	python scripts/precargar_cuentas.py --ficticias
Dar rol de administrador	Incluir rol admin en el CSV de esa cuenta; el script actualiza el rol si ya existía
Reiniciar el registro de alguien que olvidó su contraseña	En el chat, menú de administrador, «Reiniciar registro de una cuenta»; o python scripts/precargar_cuentas.py --reiniciar-registro <cuenta>
Ver quién ya se registró	Menú de administrador, «Usuarios registrados»

El script no imprime números de cuenta ni nombres. El historial de una persona se pierde al reiniciar su registro, porque se liga a su identificador interno.

5.7 Monitoreo y costos

El panel de administración (/admin-metrics) muestra costo por modelo (incluidas la reescritura y las búsquedas), usuarios activos, consultas por carrera, tiempos p50 y p95 y preguntas sin resultado agrupadas y anónimas. Los datos de AWS aparecen como no disponibles hasta que se implemente la etapa 2 (sección 7.3). Mientras tanto, revisa el costo de AWS en Billing y el de OpenAI en su panel de uso.

Referencia de costos al corte del 10/11/2026: OpenAI 0.16 USD en el mes y AWS en 0.00 USD. El modelo Avanzado cuesta unos 0.00026 USD por consulta. No hay tope duro de gasto en OpenAI: configura un límite de presupuesto en la cuenta (riesgo R02 de la planeación).

5.8 Respaldo y recuperación

Tabla 5.3: Qué respaldar y cómo recuperarlo.

Elemento	Dónde está	Cómo respaldarlo	Recuperación
Cuentas e historial	data/usuarios.db (instancia)	Copia con fecha en ~/respaldos/ antes de cada despliegue; copia mensual fuera de la instancia	Restaurar el archivo y reiniciar el backend; requiere el mismo .env
Claves y secretos	.env (instancia y equipos del equipo)	Copia cifrada en un gestor de contraseñas del equipo	Sin las claves CUENTA_FERNET_KEY y CUENTA_HMAC_KEY los datos cifrados no se pueden leer
Base vectorial	data/lancedb	Se regenera desde Procesados/; guarda una copia con fecha antes de sobrescribir	Copiar la carpeta o volver a vectorizar

Elemento	Dónde está	Cómo respaldarlo	Recuperación
PDF originales	Pre Procesados/ y data/acervo_original	Copia fuera de Git (pesan cientos de MB)	scripts/preparar_acervo_original.py
Código	GitHub	Ya está versionado	git clone
Infraestructura de apagado	infra/f5/ y la pila nexus-fi-f5	Está en Git como plantilla	python scripts/f5_desplegar.py desplegar

5.9 Solución de problemas

Tabla 5.4: Síntomas frecuentes en operación.

Síntoma	Causa probable	Qué hacer
La página muestra «Nexus FI está en reposo»	La instancia se apagó por inactividad	Pulsar el botón y esperar menos de 2 minutos; o encenderla en la consola de EC2
El botón de encendido no hace nada	La Lambda o su permiso fallaron	Revisar los registros de nexus-fi-f5-despertar en CloudWatch; ver las pruebas de tests/test_f5.py
Error 503 «inicio de sesión no está configurado»	Faltan AUTH_JWT_SECRET, CUENTA_HMAC_KEY o CUENTA_FERNET_KEY en el .env	Completar el .env y reiniciar el backend
Error 503 «modelo no disponible»	Falta la clave de ese modelo	Agregar la variable de la clave y reiniciar; revisar /api/health
Error 429 en el chat	Cuota agotada del usuario para ese modelo	Esperar o usar el otro modelo; en desarrollo, arrancar con --dev
Error 429 en el login	5 intentos fallidos en 15 minutos	Esperar o reiniciar el backend (el contador está en memoria)
«No se encontró información oficial suficiente»	Ningún fragmento superó el umbral 0.52	Reformular; revisar si el tema está en el acervo; ver las preguntas sin resultado del panel
Las citas no abren el PDF	Falta data/acervo_original en la instancia o venció el enlace	Copiar los PDF y reiniciar; el enlace dura 10 minutos
El frontend muestra datos viejos	Caché del navegador o del service worker	Recargar con Ctrl + F5; las páginas ya se revalidan en cada carga
Falla el MCP o la CLI de AWS con «Invalid request parameters»	La sesión de AWS venció	Ejecutar aws login --profile nexus-fi
Error de OpenAI en una consulta	Clave inválida, sin saldo o límite de tasa	Revisar la clave y el saldo; la API responde con el texto del fragmento principal como respaldo

CAPÍTULO 6. CALIDAD Y PRUEBAS

6.1 Pruebas automáticas

La suite se ejecuta con python -m pytest tests -q y tiene 141 pruebas que pasan en unos 45 segundos. Ninguna llama a OpenAI ni a AWS: usan una base SQLite temporal, claves de prueba, cuentas inventadas y dobles del buscador, del embedder y del modelo. tests/conftest.py activa siempre el límite de consultas, sin importar el .env local, y debe cargarse antes de importar backend.app.

Tabla 6.1: Cobertura de la suite por archivo.

Archivo	Pruebas	Qué valida
test_auth.py	24	Registro, inicio y cierre de sesión, bloqueo por intentos, roles y administración de cuentas
test_modelos.py	19	Tabla de modelos, parámetros por modelo, cuotas independientes y errores 429
test_contexto.py	16	Recorte del historial y reescritura de preguntas de seguimiento
test_metricas.py	14	Totales del tablero y del panel de administración con datos conocidos
test_f5.py	14	Lambda de encendido con clientes simulados, plantilla CloudFormation y ajustes de CloudFront
test_documentos.py	13	Catálogo de citas, enlaces firmados, rutas seguras y visor de texto
test_rate_limiter.py	13	Límite de consultas por usuario en el middleware
test_conversaciones.py	12	Historial cifrado, aislamiento entre usuarios y conversation_id en el chat
test_busqueda_terminos.py	8	Aceptar nombres propios poco comunes que aparecen tal cual en un fragmento
test_cache_frontend.py	8	Cabecera no-cache y respuestas 304 de los archivos del frontend
Total	141	

6.2 Lo que las pruebas no cubren

Tabla 6.2: Brechas de calidad conocidas.

Brecha	Riesgo	Cómo cerrarla
Sin pruebas automáticas del frontend	Un cambio en app.js puede romper el chat sin que ninguna prueba falle	Pruebas de extremo a extremo con Playwright sobre una instancia local con cuentas ficticias
La ingesta no tiene pruebas propias	Un cambio en el segmentador altera los fragmentos y las citas	Pruebas con documentos de ejemplo pequeños y resultados esperados
La calidad de las respuestas no se mide en continuo	Un cambio de acervo, prompt o modelo puede degradar respuestas sin que nadie lo note	Conjunto de preguntas de referencia con respuesta esperada (sección 6.3)
Sin pruebas de carga	No se conoce el comportamiento con muchos usuarios a la vez	Prueba de carga controlada contra una instancia local y con tope de gasto
Sin auditoría de accesibilidad	RNF04 sigue parcial	Revisión contra WCAG 2.1 AA con herramientas automáticas y lector de pantalla

6.3 Verificar la calidad de las respuestas

Un modelo de lenguaje puede redactar con seguridad algo falso. En la fase F2 se dio por buena una respuesta de servicio social con «seiscientas horas» cuando el reglamento dice 480 horas; la lección del proyecto es que toda respuesta se verifica contra el documento fuente, nunca contra otra respuesta del modelo.

scripts/comparar_modelos.py pasa las 20 preguntas de scripts/preguntas_comparacion.json por el mismo flujo que usa producción (búsqueda, prompt y parámetros), con una base temporal y una cuenta ficticia, y mide por modelo aciertos, cita correcta, latencia, tokens y costo. Cada corrida cuesta menos de 0.10 USD y guarda un reporte en docs/02_Ejecucion/. Úsalo después de cualquier cambio de acervo, prompt o modelo y amplía el archivo de preguntas con los errores que encuentres.

```
python scripts/comparar_modelos.py
python scripts/comparar_modelos.py --modelos gpt-6-luna --esfuerzo medium
```

Los casos de prueba funcionales del curso (CP-01 a CP-24) y sus resultados están en el Documento Maestro de Ejecución.

CAPÍTULO 7. ESTADO FINAL, DEUDA TÉCNICA Y TRABAJO FUTURO

7.1 Lo que se entrega funcionando

Tabla 7.1: Fases técnicas terminadas.

Fase	Resultado
F1. Historial	Conversaciones y mensajes cifrados por usuario; listar, abrir y borrar
F2. Contexto	Últimos 3 pares en el prompt y reescritura de preguntas de seguimiento; filtro de fragmentos casi duplicados y regla de semestres explícitos
F3. Modelos y cuotas	Selector Rápido y Avanzado con cuotas independientes y costos con la tarifa de cada modelo
Citas consultables	Cada cita abre el PDF original en la página citada o el visor de texto
F4. Métricas reales	Tablero personal y panel de administración desde la base, sin datos de demostración
F5. Apagado automático	Pila nexus-fi-f5 desplegada y probada: se apaga sola y vuelve en menos de 2 minutos

7.2 Defectos conocidos y deuda técnica

Esta lista incluye lo que se detectó al preparar este documento y el manual de usuario. Ninguno impide el uso del piloto, pero conviene atenderlos en el orden de la sección 7.3.

Tabla 7.2: Registro de defectos conocidos (DC).

ID	Descripción	Dónde	Sugerencia
DC-01	La pantalla principal dice «211 documentos y 3,977 vectores» (bienvenida, pie y mensaje de respaldo) y /api/stats devuelve 211 fijo; los datos reales son 198 documentos y 3,340 fragmentos	frontend/index.html (líneas 74 y 109), frontend/app.js (648) y backend/app.py (/api/stats)	Corregido el 11/11/2026: las cifras se leen de /api/stats (base vectorial). Pendiente de desplegar
DC-02	En el chat, Enter no envía el mensaje; hay que pulsar el botón	frontend/app.js	Corregido el 11/11/2026: Enter envía y Mayús + Enter inserta un salto de línea. Pendiente de desplegar
DC-03	Al preguntar «¿Qué requisitos tiene el servicio social?» y luego «¿y cuántas horas son?», el asistente puede responder 600 horas. El Reglamento del Servicio Social (art. 16) dice 480; los Lineamientos de Educación Profesional a Distancia (art. 33) dicen «no menor de seiscientas horas» y aplican a alumnos de licenciatura a distancia	Recuperación en la pregunta de seguimiento; documento de lineamientos a distancia en el acervo	Que el prompt pida distinguir modalidad (presencial o a distancia) cuando las fuentes difieran, y decidir si ese documento se marca por modalidad o se excluye del piloto de ICO
DC-04	/api/health es público y muestra los primeros 11 y últimos 4	backend/app.py (mask_key, get_health)	Quitar las claves enmascaradas de las

ID	Descripción	Dónde	Sugerencia
	caracteres de las claves de OpenAI; la telemetría del chat también las enmascara así. Además declara environment «development/local» fijo		respuestas públicas y mostrar solo si están configuradas, o exigir rol admin
DC-05	Los tokens revocados y el contador de intentos fallidos viven en memoria: se pierden al reiniciar y no se comparten entre procesos	core/auth/tokens.py y routes.py	Persistirlos en SQLite si se usa más de un proceso o se reinicia seguido
DC-06	CORS permite cualquier origen (allow_origins con asterisco)	backend/app.py	Restringir al dominio de CloudFront y a localhost en desarrollo
DC-07	Los comentarios llaman RF13 al umbral de similitud y WBS 1.4.2 a varios módulos; en el Documento Maestro el umbral es RF11	Comentarios y respuestas del código	Unificar la numeración con el Documento Maestro
DC-08	No hay retención del historial ni aviso de privacidad definitivo: nada se purga	core/chat/store.py	Decidir plazo, redactar el aviso y programar la purga
DC-09	115 fragmentos de un mapa curricular con texto revuelto siguen en el acervo (opción C pendiente)	Procesados/ y la base vectorial	Retirarlos o sustituirlos por una versión limpia
DC-10	Huecos de recuperación: opciones de titulación (sale la Guía de Trámites y no el Reglamento de Evaluación Profesional), «décimo semestre» y nombre de la coordinadora	Acervo y búsqueda	Agregar fuentes piloto o ajustar la búsqueda y volver a correr la comparación
DC-11	Algunos temarios perdieron horas y créditos al extraerse	Procesados/02_Planes_de_Estudio_ICO	Reprocesar esos documentos y validar con el original
DC-12	26 de las 29 referencias de acervo del Documento Maestro tienen enlaces que ya no abren	docs/01_Planeacion	Citar rutas que abran o la consulta desde Nexus FI
DC-13	El panel de administración no muestra datos de AWS (aws devuelve null)	backend/app.py y core/metricas.py	Etapa 2 de F4 (sección 7.3)
DC-14	La dirección IP de la instancia cambia en cada encendido; el origen de CloudFront se actualiza con la Lambda	infra/f5/	Alternativa: IP elástica (unos 3.6 USD al mes) si la actualización da problemas

7.3 Trabajo sugerido, en orden de prioridad

Los esfuerzos son estimaciones orientativas: S es menos de un día, M de dos a cinco días y L más de una semana.

Tabla 7.3: Propuesta de trabajo para el relevo.

Prioridad	Mejora	Esfuerzo	Por qué
1	Desplegar en la instancia las correcciones de DC-01 y DC-02 (ya fusionadas, con pruebas; el manual de usuario ya las describe)	S	Eran errores visibles para todas las personas usuarias; en producción siguen hasta que se despliegue
1	Resolver DC-03 (modalidad en las respuestas sobre servicio social)	M	Una respuesta equivocada sobre un trámite obligatorio erosiona la confianza
1	Definir retención del historial y aviso de privacidad (DC-08)	M	Decisión del equipo y requisito antes de abrir a más personas
2	Conjunto de preguntas de referencia ampliado y automático	M	Detecta regresiones al cambiar acervo, prompt o modelo
2	Etapa 2 de F4: rol IAM de solo lectura en la instancia, CloudWatch y Cost Explorer en el panel	M	Costo y estado reales sin entrar a AWS (Cost Explorer cobra 0.01 USD por llamada: usar caché de unas 6 horas)
2	Endurecimiento de seguridad (DC-04, DC-05, DC-06)	S a M	Reduce la superficie expuesta con cambios pequeños
2	Completar huecos de recuperación y reprocesar temarios (DC-10, DC-11)	M	Mejora RF01, RF02 y RF05, que están parciales
3	Medición formal de RNF01 y auditoría WCAG (RNF04)	S y M	Cierra requisitos que hoy están por medir o parciales
3	Pruebas de extremo a extremo del frontend	M	Cierra la mayor brecha de la suite
3	Tope diario del modelo Avanzado	S	Hoy no tiene límite diario; depende de la decisión del equipo
3	Habilitar otra carrera (sección 5.5)	L	Requiere acervo, padrón y decisión institucional
3	Caché semántica (RF12)	M	Solo si el consumo de tokens lo justifica; hoy el costo es mínimo

7.4 Decisiones pendientes del equipo

Estas decisiones no son técnicas y no deben tomarse solo desde el código: retención del historial y aviso de privacidad; tope diario del modelo Avanzado; si el acervo mantiene documentos que difieren por modalidad (DC-03) o el mapa curricular revuelto (DC-09); y quién será el responsable institucional del padrón y del acervo después del piloto.

7.5 Riesgos para la continuidad y traspaso de accesos

Tabla 7.4: Riesgos de continuidad.

Riesgo	Impacto	Mitigación
Gasto sin tope en OpenAI	Un abuso o un error de código puede generar costos	Límite de presupuesto en la cuenta, cuotas por usuario activas en producción y revisión semanal
Crédito de AWS agotado	La instancia deja de operar	Revisar el crédito cada mes; mantener el apagado automático
Accesos concentrados en una persona	Si ella se va, nadie puede desplegar o recuperar datos	Entregar los accesos con la lista siguiente y documentar quién los tiene
Acervo desactualizado	Respuestas con requisitos o fechas viejas	Calendario de revisión y fecha de vigencia de cada fuente

Riesgo	Impacto	Mitigación
Rotación del personal de servicio social	Pérdida de contexto	Este documento, la bitácora del plan de implementación y sesiones de relevo
Cambios en los modelos de OpenAI	Un modelo se retira o cambia de precio o parámetros	Tabla MODELOS como fuente única y comparación periódica
Datos personales	El historial guarda preguntas de personas identificables por cuenta	Cifrado vigente, aviso de privacidad y política de retención (DC-08)

Lista de verificación para entregar el proyecto. Cada elemento debe pasarse por un canal seguro (nunca por correo abierto, chat grupal o Git) y, al terminar, el equipo saliente debe rotar las claves que compartió y crear accesos nominales para quien continúa. El estado de cada punto lo llena el equipo.

Tabla 7.5: Lista de verificación del traspaso.

Elemento	Qué se entrega	Quién lo tiene hoy	Estado
Repositorio	Acceso al repositorio de GitHub y a la rama main	Project Manager (a confirmar)	Por entregar
Archivo .env	Claves de OpenAI (tres) y secretos de sesión y cifrado de producción	Project Manager (a confirmar)	Por entregar
Base vectorial	Carpeta data/lancedb	Equipo de datos	Por entregar
PDF originales	Carpeta Pre Procesados/ y data/acervo_original	Equipo de datos	Por entregar
Padrón de cuentas	CSV con número de cuenta, carrera y rol (datos privados)	Project Manager (a confirmar)	Por entregar
Acceso a AWS	Usuario IAM nominal con permisos acotados, llave SSH de la instancia y perfil aws login	Equipo de nube	Por entregar
Cuenta de OpenAI	Acceso al panel de uso y presupuesto	Project Manager (a confirmar)	Por entregar
Documentos del curso	Documentos Maestros, matrices y evidencias en docs/	Equipo	Entregado en el repositorio
Rotación de claves	Rotar las claves de OpenAI y AUTH_JWT_SECRET al terminar el relevo (no cambiar CUENTA_FERNET_KEY ni CUENTA_HMAC_KEY)	Project Manager	Por hacer

CAPÍTULO 8. TUS PRIMERAS DOS SEMANAS

Plan sugerido para llegar a aportar con confianza. Puedes ajustarlo a tu tiempo y a tu perfil.

Tabla 8.1: Plan de incorporación.

Cuándo	Actividad	Resultado
Día 1	Leer los capítulos 1 y 3, clonar el repositorio, instalar y correr las pruebas	141 pruebas en verde en tu equipo
Día 2	Recibir el .env y la base vectorial, arrancar con --dev, registrar una cuenta ficticia y hacer diez preguntas abriendo las fuentes	Conoces el comportamiento esperado
Día 3	Seguir una consulta de punta a punta leyendo /api/chat, core/chat/modelos.py y vector_store.py	Puedes explicar la figura 3
Día 4	Leer el Manual de usuario y el Documento de Monitoreo y Control	Entiendes cómo se usó y cómo se controló el proyecto
Día 5	Corregir DC-06 (restringir CORS) con su prueba	Primer cambio fusionado
Semana 2	Corregir DC-04, correr scripts/comparar_modelos.py y reproducir DC-03	Cambio de seguridad y línea base de calidad
Semana 2	Acompañar un despliegue con quien tenga acceso a AWS	Entiendes el procedimiento de la sección 5.2

ANEXO A. VARIABLES DE ENTORNO

Plantilla completa en .env.example. Los valores reales nunca van en Git ni en este documento.

Tabla A.1: Variables del archivo .env.

Variable	Para qué sirve	Obligatoria
OPENAI_API_KEY_EMBEDDINGS	Clave de embeddings (text-embedding-3-small); calcula el vector de cada consulta	Sí (o OPENAI_API_KEY)
OPENAI_API_KEY_CHAT_4O_MINI	Clave del modelo Rápido y de la reescritura de preguntas	Sí (o OPENAI_API_KEY)
OPENAI_API_KEY_GPT6_LUNA	Clave del modelo Avanzado	Solo para el modo Avanzado
OPENAI_API_KEY	Clave general de respaldo para embeddings y gpt-4o-mini	No
AUTH_JWT_SECRET	Secreto para firmar los tokens de sesión y los enlaces a PDF	Sí
CUENTA_HMAC_KEY	Clave de la huella HMAC del número de cuenta	Sí; no cambiar con datos existentes
CUENTA_FERNET_KEY	Clave de cifrado Fernet de datos personales e historial	Sí; no cambiar con datos existentes
USUARIOS_DB_PATH	Ruta de la base SQLite (por defecto data/usuarios.db)	No
RATE_LIMIT_ENABLED	Activa o apaga el límite de consultas (true en producción; --dev lo apaga)	No (true por defecto)
HOST y PORT	Dirección y puerto del servidor local	No
ACERVO_ORIGINALES_DIR	Carpeta alterna de PDF originales para las citas	No
LANCEDB_URI y LANCEDB_TABLE_NAME	Ubicación y nombre de la tabla vectorial (por defecto ./data/lancedb y nexus_documents)	No
EMBEDDING_MODEL y EMBEDDING_DIMENSIONS	Modelo y dimensiones de embeddings (text-embedding-3-small, 1,536); si cambian hay que revectorizar todo	No
GEMINI_API_KEY	Diagnósticos alternativos opcionales	No
AWS_REGION	Región de los servicios de AWS (us-east-2 en producción)	No

ANEXO B. GLOSARIO

Tabla B.1: Términos técnicos y del proyecto.

Término	Significado
RAG	Recuperación aumentada por generación: buscar fragmentos relevantes y pedir a un modelo que redacte la respuesta usando solo esos fragmentos
Embedding o vector	Lista de números que representa el significado de un texto; textos parecidos tienen vectores cercanos
Fragmento (chunk)	Trozo de un documento de unos 650 tokens con el que se construye la base vectorial
Umbral de similitud	Valor mínimo (0.52) de parecido entre la pregunta y un fragmento para que se use como fuente
LanceDB	Base de datos vectorial local, guardada en la carpeta data/lancedb
Token	Unidad de texto con la que los modelos miden entrada, salida y costo
Prompt	Instrucciones y contexto que se envían al modelo junto con la pregunta
Cuota	Número máximo de consultas por usuario, por hora y por día, en cada modelo
JWT	Token firmado que prueba que la persona inició sesión; en Nexus FI dura 8 horas
Fernet, HMAC y bcrypt	Cifrado reversible de datos personales, huella para buscar sin descifrar y hash de contraseñas
PWA	Aplicación web que puede instalarse y adaptarse al celular
CloudFront, EC2, Lambda, S3 y OAC	Servicios de AWS: distribución de contenido, servidor virtual, función sin servidor, almacenamiento y control de acceso del bucket de la página de reposo
Frontmatter	Encabezado con metadatos (id, título, categoría, carrera, archivo fuente) al inicio de cada documento procesado
SC, CP, D, DC y F	Solicitud de cambio, caso de prueba, hallazgo del Documento de Ejecución, defecto conocido de este documento y fase técnica del plan de implementación
Piloto	Etapa de prueba con un grupo reducido (ICO) antes de abrirlo a más carreras

ANEXO C. REFERENCIAS

Documentación externa útil para trabajar en el proyecto:

Tabla C.1: Referencias externas.

Tema	Dirección
FastAPI	https://fastapi.tiangolo.com
Docker Compose	https://docs.docker.com/compose/
pytest	https://docs.pytest.org
OpenAI: modelos, precios y parámetros	https://developers.openai.com
AWS: documentación de EC2, CloudFront, Lambda y CloudWatch	https://docs.aws.amazon.com
Repositorio del proyecto	https://github.com/igream/Nexus-FI
Producción (prueba piloto)	https://d2j5rd06t9r4yq.cloudfront.net

Los precios y los parámetros de los modelos cambian: verifícalos en la documentación de OpenAI el día que vayas a usarlos.