INFORME TÉCNICO

Herramienta de Extracción y Procesamiento de Contenido de Redes Sociales

Proyecto	Nexus FI (Facultad de Ingeniería — UAEMéx)
Objetivo	Extracción, procesamiento y digitalización de publicaciones oficiales (Facebook e Instagram) para la base de conocimiento institucional.

Resumen Ejecutivo

Para alimentar el repositorio de información de la Facultad de Ingeniería, se desarrolló un *pipeline* automatizado de extracción de datos locales que procesa publicaciones oficiales, descarga de forma controlada el material gráfico y extrae el texto embebido en convocatorias, carteles e infografías mediante Reconocimiento Óptico de Caracteres (OCR). El proyecto se estructuró y ejecutó en dos fases metodológicas.

Fase 1: Intento de Lectura Directa con Antigravity

1.1 Enfoque y Limitaciones Detectadas

En la primera etapa se evaluó la extracción directa de información navegando sobre las interfaces web públicas de Facebook e Instagram mediante herramientas de automatización de navegador.

- **Muros de autenticación (*login walls*):** Meta restringe de forma severa el consumo de contenido público a usuarios no autenticados. Tras consultar un número muy limitado de publicaciones, las plataformas despliegan pantallas de bloqueo que exigen inicio de sesión obligatorio.
- **Seguridad y políticas de uso:** En estricto apego a las buenas prácticas de seguridad informática, no se ingresaron credenciales institucionales ni contraseñas personales para sortear estos bloqueos. Utilizar cuentas en procesos de navegación automatizada habría expuesto los perfiles oficiales a bloqueos por parte de los sistemas antibot de Meta.

> **Resultado:** La extracción directa resultó parcial, inestable y técnicamente inviable para un flujo periódico de datos.

Fase 2: Herramienta de Extracción y Procesamiento con Apify y Python

2.1 Arquitectura de la Solución

Para resolver las limitaciones de la Fase 1, se adoptó un modelo desacoplado:

- **Recolección especializada:** uso de *scrapers* dedicados en la nube (Apify) para obtener conjuntos de datos locales estructurados en formato JSON.
- **Pipeline local en Python (`procesar_posts.py`):** un programa desarrollado a medida para procesar tanto Facebook como Instagram sin depender de servicios externos de terceros para el análisis de texto.

2.2 Componentes Técnicos Implementados

- **Base de datos SQLite (`nexus_fi.db`):** indexación relacional mediante ID único. Almacena fecha, texto de la publicación, métricas públicas de interacción (*likes*, *shares*), enlace oficial, detección de video y registro de páginas compartidas.
- **Protección de privacidad:** el diseño descarta de manera programática autores de comentarios, hilos de interacción y perfiles individuales, recopilando únicamente la información institucional pública.
- **Descarga multimedia idempotente (`imagenes/`):** descarga fotos de publicaciones directas y compartidas. Para publicaciones de tipo video o carrusel, se descarga y almacena exclusivamente la imagen de portada bajo el formato `<postId>_<número>.jpg`. La idempotencia garantiza que, si el script se ejecuta múltiples veces, no vuelve a descargar imágenes existentes ni duplica registros.
- **Motor OCR local (Tesseract en español):** integración directa con el motor Tesseract OCR (`lang='spa'`) para transcribir el texto contenido en volantes de conferencias, convocatorias de servicio social y avisos administrativos.

2.3 Resultados Empíricos Obtenidos

A continuación se resumen los resultados obtenidos al procesar los *datasets* oficiales de la Facultad:

Plataforma / Cuenta	Publicaciones procesadas	Tipo de contenido	Imágenes / portadas descargadas	Textos extraídos con OCR	Errores / fallas
Facebook (FIUAEM)	5	2 directas, 2 compartidas, 1 video	20	6	0
Instagram (@ingenieriauaemex)	5	3 carruseles, 1 video, 1 aviso	5	3	0
Total Global FIUAEM	**10**	—	**25**	**9**	**0**

Nota: el total de 10 publicaciones corresponde a que, en la prueba final de Instagram, se extrajeron exactamente 5 publicaciones, aunque en pruebas de desarrollo previas se hayan procesado más.

Hallazgos relevantes del OCR

- **Infografías complejas:** se extrajo con alta fidelidad el texto completo de programas académicos (p. ej., el Congreso Internacional en Ingeniería en Desarrollo Sostenible, recuperando más de 1,600 caracteres de agenda).
- **Avisos oficiales:** detección precisa de comunicados clave para alumnos (p. ej., avisos sobre trámites de Servicio Social).
- **Persistencia local:** dado que las URLs de Meta CDN caducan transcurrido un periodo de tiempo, almacenar las imágenes en disco y el texto en SQLite asegura que la información permanezca

accesible de forma permanente.

Nota Técnica sobre Restricciones de Meta y Recomendación

> **ADVERTENCIA — Restricciones y políticas de Meta.** Meta ajusta periódicamente sus mecanismos de detección automatizada, la caducidad de tokens en enlaces multimedia y las restricciones de acceso no autenticado. El raspado de datos externo está sujeto a bloqueos repentinos de infraestructura y a variaciones imprevistas en los selectores de datos.

Recomendación estratégica

Para garantizar la continuidad, sostenibilidad y escalabilidad del canal de datos a largo plazo, se recomienda solicitar formalmente acceso o coordinación con los administradores de las páginas oficiales de la Facultad de Ingeniería (Unidad de Comunicación / Redes Sociales):

- **Acceso a la Meta Graph API oficial:** permite obtener de manera directa, autorizada y sin riesgo de bloqueo las publicaciones y recursos en tiempo real mediante tokens oficiales de lectura de página.
- **Canal centralizado de contenidos:** establecer un repositorio compartido donde el equipo de diseño y comunicación deposite simultáneamente los comunicados e infografías oficiales para su ingesta inmediata en la base de datos.

Referencias (IEEE)

[1] Apify, "Instagram Post Scraper," 2026. [En línea]. Disponible: https://apify.com/apify/instagram-post-scraper

[2] Apify, "Facebook Posts Scraper," 2026. [En línea]. Disponible: https://apify.com/apify/facebook-posts-scraper

[3] Tesseract OCR, "Tesseract Open Source OCR Engine," GitHub, 2026. [En línea]. Disponible: https://github.com/tesseract-ocr/tesseract

[4] Meta, "Platform Terms and Developer Policies," 2026. [En línea]. Disponible: https://developers.facebook.com/terms/